CONFIDENTIEL — USAGE INTERNE

US Attorneys Data Acquisition Strategy

Analyse exhaustive des sources de données pour 1.3M+ avocats américains

1.3M+	50	10
AVOCATS US ACTIFS	ÉTATS + DC	AGENTS DÉPLOYÉS

Projet: us-attorneys.com — **Date**: 16 mars 2026
Objectif: 8.8M+ pages SEO programmatiques

Règle d'or : mieux aucune information qu'une information fausse

1. Résumé exécutif

Vue d'ensemble des sources identifiées par 10 agents de recherche parallèles.

Constat principal

New York est le seul état à publier un dataset open data complet (CSV/API Socrata) pour ses avocats. Pour les autres états, les voies les plus fiables sont : **demandes de records publics** (bulk officiel) et **scraping ciblé** (testé et prouvé).

État actuel de la base de données

TABLE	RECORDS	STATUT
States	57 (50 + DC + 6 territoires)	Complet
Counties	3 222	Complet
Cities (locations_us)	32 109	Complet
ZIP Codes	33 781	Complet
Attorneys	334 468 (NY uniquement)	1 état / 50
→ Liés à une ville	178 367 (53.3%)	En cours

Potentiel d'acquisition par phase

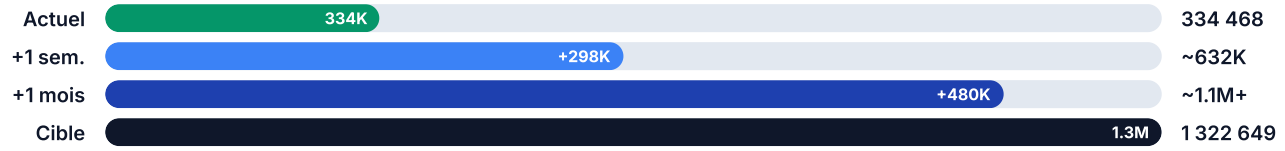

Classification des sources

Tier 1 — Bulk officiel, immédiatement actionnable

Datasets complets fournis directement par les autorités. Qualité maximale, bar numbers vérifiés.
États : NY (done), FL (email gratuit), GA ($6.5K)

Tier 2 — Demandes formelles (PIA/FOIA), délai 2-6 semaines

Demandes de records publics aux barreaux d'état. Données officielles, coût modéré.
États : TX ($200-500), OH (gratuit/faible), NJ ($200-500), PA (sur devis), MA (frais copie)

Tier 3 — Scraping testé et prouvé (fallback)

Méthodes testées avec 50-110 records. Fiable mais plus fragile à grande échelle.
États : CA (HTML scraping, ~14h), IL (ASP.NET grid, ~6-8h), TX (ColdFusion, ~8h)

2. Tier 1 — Sources bulk officielles

Données complètes et vérifiées, disponibles immédiatement ou sous quelques jours.

New York — NY Open Data DONE

Source

data.ny.gov — NYS Attorney Registrations
`eqw2-r5nb`

Format

CSV, JSON, XML, API Socrata (SODA)

Coût

Gratuit

Records

334 468

Champs clés

Nom, prénom, bar number, statut, adresse, ville, état, ZIP, date d'admission, lieu de pratique

Mise à jour

Quotidienne

Florida — FL Bar Public Records Request RECOMMANDÉ

Source

Florida Bar — Membership Records Department
`addressing@floridabar.org`

Format

Excel (envoyé par email)

Coût

Gratuit par email
Frais uniquement si DVD/clé USB

Records estimés

~108 000

Champs

Bar#, nom, adresse, firm, ville, état, ZIP, téléphone, fax, email, county code, circuit code + 23 sections + 26 certifications sur demande

Mise à jour

Quotidienne

Action requise

Télécharger le formulaire PDF depuis `floridabar.org/about/faq/rec-request/`, remplir et envoyer à **addressing@floridabar.org**. Demander : «All MIGS, Both (In + Out of State), All Circuits».

Georgia — State Bar Mailing Lists PAYANT

Source

State Bar of Georgia — Mailing Lists
`gabrielled@gabar.org`

Format

Excel (.xls), Database (.dbf), ASCII (.txt)

Coût

15¢/record = ~$6 517
Minimum $25/commande. Délai 7-10 jours.

Records

~56 347

(43 447 actifs)

Champs

Nom, adresse, ville, county, state, ZIP, law school, date admission, date naissance, sections, judicial circuit, member type, genre

Mise à jour

Quotidienne

USPTO Patent Practitioner Roster GRATUIT

Source

US Patent & Trademark Office
`uspto.gov/attorney-roster/attorney.zip`

Coût

Gratuit (Public Domain)

Records

~48 625 patent attorneys/agents (national)

Champs

Nom, n° enregistrement, titre, ville, état, ZIP, statut

3. Tier 2 — Demandes de records publics

Données officielles obtenues via PIA/FOIA/Open Records. Délai : 2 à 6 semaines.

ÉTAT	AUTORITÉ	CONTACT	COÛT ESTIMÉ	RECORDS	FORMAT
Texas	State Bar of TX — PIA	`texasbar.govqa.us`	$200–500	~130 000	CSV/Excel
Ohio	Supreme Court — Atty Reg.	`attyreg@sc.ohio.gov`	Gratuit/faible	~37 000	À négocier
New Jersey	NJ Courts — CAMS Report	Superior Court Clerk's Office	$200–500	~100 000	Text délimité
Pennsylvania	PA Disciplinary Board	717-772-8572	Sur devis	~90 000	À négocier
Massachusetts	Board of Bar Overseers	`webmaster@massbbo.org`	Frais copie	~70 000	À négocier

Détails par état

Texas — Public Information Act (PIA)

Le State Bar of Texas est soumis au Texas PIA. Soumettre via le portail **texasbar.govqa.us**. Demander le bar roll complet en format électronique (CSV/Excel). Champs publics : nom, bar card number, adresse cabinet, téléphone, date de licence, statut. Les adresses personnelles et SSN sont confidentiels.

Alternative : Programme de mailing lists via `listmail@texasbar.com` (payant, prix non publié).

Alternative rapide : OpenGovUS (`opengovus.com/texas-lawyer`) semble avoir ~130K avocats scrapables.

Ohio — Public Records Request

Contacter le Registration and CLE Section de la Supreme Court of Ohio. L'Ohio Public Records Act (R.C. 149.43) oblige la fourniture des records électroniques dans leur format natif. Champs : nom, adresse pro, téléphone, n° enregistrement, statut, genre, date naissance, école de droit.

Note technique : Le domaine `supremecourt.ohio.gov` est inaccessible depuis notre machine (timeout). La demande officielle contourne ce problème.

New Jersey — CAMS Report

Le **Central Attorney Management System** (CAMS) des NJ Courts fournit des rapports de données d'avocats sur demande. Record layout PDF disponible. Mise à jour 2x/an. Restriction : interdiction de miner/revendre sans autorisation écrite.

Attention : Le portail de recherche en ligne interdit explicitement l'accès automatisé («May not be accessed by any automated program»).

Pennsylvania — Public Data Request

Le PA Disciplinary Board accepte les demandes de données publiques via un formulaire dédié, avec tarification au cas par cas. Champs : nom, statut (active/inactive/suspended/disbarred), adresse, historique disciplinaire, assurance malpractice.

Massachusetts — Chapter 66 Public Records Request

Le Board of Bar Overseers (BBO) est probablement soumis aux lois de records publics du Massachusetts (Chapter 66). Soumettre une demande formelle. Champs disponibles via leur lookup : nom, BBO#, adresse, date admission, historique disciplinaire.

4. Tier 3 — Scraping testé et prouvé

Méthodes validées avec 50–110 records. Utilisables en fallback si les demandes officielles tardent.

ÉTAT	MÉTHODE	TEST	TEMPS FULL	FIABILITÉ	RISQUES
CA	HTML scraping profils CalBar apps.calbar.ca.gov/attorney/Licensee/Detail/{id}	95 records	~14h	Bonne	Rate limiting possible après des heures
IL	ASP.NET MvcGrid + antiforgery 4 étapes : GET search → POST form → Grid AJAX → Details	60 records	~6–8h	Bonne	Tokens expirent, pas de bar number
TX	Session ColdFusion + cookies GET page → POST avec CFID/CFTOKEN	55 records	~8h	Moyenne	Cookies expirent, pas d'emails, HTML fragile
FL	Federal Court rolls (FLMD) apps.flmd.uscourts.gov/attyadm/	110 records	~2h	Partiel	Sous-ensemble (federal uniquement)
OH	API Ajax.ashx (Ember.js) Reverse-engineeré via Wayback Machine	0 records	N/A	Bloqué	Domaine inaccessible depuis cette machine

Détails des tests CA — Meilleur candidat scraping

Stratégie en 2 étapes

1. **Discovery** : Recherche par préfixe (AA–ZZ = 676 requêtes) → 500 liens/requête → énumère tous les ~190K avocats
2. **Detail fetch** : Profil HTML pour chaque bar number avec parsing structuré

Rate limiting

200ms entre requêtes = aucun blocage observé sur 95 tests

Qualité des données (95 records)

Nom	**100%**
Date admission	**100%**
Statut	**100%**
Ville	94%
Téléphone	74%
Firm name	69%
Email	68% (obfusqué, décodable)

Avertissement — Tolérance zéro

Le scraping à grande échelle comporte des risques : données partielles si blocage en cours de route, parsing HTML fragile, pas de garantie de complétude. **Pour chaque état, la demande officielle de records publics reste la voie recommandée.** Le scraping n'est qu'un fallback.

5. Sources nationales et commerciales

Bases de données couvrant l'ensemble du territoire américain.

Sources nationales gratuites

SOURCE	COUVERTURE	RECORDS	BAR#?	FORMAT	LICENCE
CourtListener API courtlistener.com	Fédéral (PACER)	Millions	Non	REST API	Public Domain
USPTO Roster uspto.gov/attorney-roster	National (brevets)	~48K	Oui	ZIP/Text	CC0
Harvard Dataverse Bonica & Sen dataset	National	380K	Non	R/CSV	Académique
DOJ EOIR Roster justice.gov/eoir	Immigration	~2 600	Non	PDF	Public

CourtListener — Point d'attention

L'endpoint `/api/rest/v4/attorneys/` est **restreint** («only available to select users»). Il faut contacter Free Law Project pour obtenir l'accès. Pas de bulk download pour les attorneys. Pas de bar numbers. Utile pour l'enrichissement (email, phone, firm) mais pas comme source primaire.

Fournisseurs commerciaux

FOURNISSEUR	RECORDS	PRIX	BAR#?	USAGE PUBLIC?
Martindale-Hubbell (LexisNexis)	1M+ (160 pays)	$50K–$200K+/an	Non	À négocier
UniCourt	630M+ parties/avocats	Enterprise (devis)	Possible	API
Avvo API	~1.26M (97% des US)	Gratuit (API)	Non	Non*
LeadsPlease	544K	$0.09–$0.25/record	Non	Marketing
BookYourData	373K (168K US)	$1 399 one-time	Non	Marketing
BizProspex	~1.5M worldwide	à partir de $200	Non	Marketing
HasData (par état)	Variable	$219–$279/état	Non	CSV

* Avvo API interdit la copie locale, la rétention de données, et la construction de directories indépendants. Uniquement affichage transactionnel en temps réel.

Verdict sur les fournisseurs commerciaux

Aucun fournisseur commercial ne vend la base complète des 1.3M avocats US avec bar numbers vérifiés. Les state bars restent la source primaire autoritaire. Les fournisseurs commerciaux sont utiles pour l'**enrichissement** (emails, téléphones, practice areas) mais pas comme source de vérité.

6. Plan d'action recommandé

Stratégie en 3 phases pour atteindre 1.1M+ avocats vérifiés.

Phase 1 — Actions immédiates (cette semaine)

#	ACTION	RECORDS	COÛT	DÉLAI
1	**Email au FL Bar** (addressing@floridabar.org) Formulaire Public Records Request	~108K	**Gratuit**	Quelques jours
2	**Lancer scraping CA** (CalBar HTML profils) Méthode prouvée à 95 records, 200ms/req	~190K	**Gratuit**	~14h
3	**Télécharger USPTO Roster** Téléchargement direct ZIP	~48K	**Gratuit**	Immédiat

Phase 2 — Demandes officielles (cette semaine → réponses sous 2-6 sem.)

#	ACTION	RECORDS	COÛT
4	**PIA Request Texas** (texasbar.govqa.us)	~130K	$200–500
5	**Public Records Ohio** (attyreg@sc.ohio.gov)	~37K	Faible
6	**CAMS Report NJ** (Clerk's Office)	~100K	$200–500
7	**Data Request PA** (Disciplinary Board)	~90K	Sur devis
8	**Public Records MA** (BBO)	~70K	Frais copie

Phase 3 — Scraping fallback + états supplémentaires

#	ACTION	RECORDS	CONDITION
9	**Scraping IL** (ARDC MvcGrid)	~97K	Si demande ARDC échoue
10	**Scraping TX** (ColdFusion)	~100K	Si PIA TX trop lente
11	**Achat GA Bar mailing list**	~56K	Si budget approuvé ($6.5K)
12	**CourtListener API** (enrichissement)	Enrichissement	Après obtention accès

Budget total estimé

Scénario minimal (gratuit + PIA)

NY, FL, CA, USPTO	**$0**
TX, OH, NJ PIA requests	~$1 000
PA, MA requests	~$500
Total	**~$1 500**
Records estimés	**~1.0M**

Scénario complet (+ GA + enrichissement)

Scénario minimal	$1 500
GA mailing list	$6 500
HasData IL + enrichissement	~$500
Total	**~$8 500**
Records estimés	**~1.1M+**

Timeline

SEMAINE	ACTION	TOTAL CUMULÉ
S1 (actuel)	NY done + envoyer emails FL/TX/OH/NJ/PA/MA + lancer CA scraping + USPTO	~572K
S2	FL Excel reçu + CA scraping terminé + linking	~680K

SEMAINE	ACTION	TOTAL CUMULÉ
S3–4	Réponses TX, OH, NJ arrivent	~950K
S5–6	Réponses PA, MA + scraping IL fallback	~1.1M+

7. Annexes

Références, contacts, et considérations légales.

A. Annuaire des contacts officiels

ÉTAT	ORGANISME	EMAIL	TÉLÉPHONE
FL	FL Bar Membership Records	`addressing@floridabar.org`	850-561-5674
TX	State Bar of TX — Lists	`listmail@texasbar.com`	800-204-2222 ×1383
OH	Supreme Court Atty Reg.	`attyreg@sc.ohio.gov`	614-387-9320
IL	ARDC Registration	`registration@iardc.org`	312-565-2600
NJ	NJ Courts Clerk's Office	(formulaire en ligne)	—
PA	PA Disciplinary Board	(formulaire)	717-772-8572
MA	Board of Bar Overseers	`webmaster@massbbo.org`	—
GA	State Bar of GA	`gabrielled@gabar.org`	404-527-8777
CA	CalBar Public Records	`calbarca.nextrequest.com`	213-765-1400

B. Sources de données par population d'avocats

ÉTAT	AVOCATS ACTIFS (ABA 2025)	SOURCE IDENTIFIÉE	PRIORITÉ
NY	181 227	Open Data CSV Done	★★★
CA	181 048	HTML Scraping CalBar	★★★
TX	113 330	PIA Request / Scraping	★★★
FL	97 426	Public Records Excel	★★★
IL	96 821	ARDC Scraping / Contact	★★
NJ	~100 000	CAMS Report	★★
PA	~90 000	Public Data Request	★★
MA	~70 000	Public Records Request	★★
GA	43 447	Mailing List ($6.5K)	★
OH	37 086	Public Records Request	★★

Source : ABA National Lawyer Population Survey, janvier 2025. Total national : 1 322 649 avocats actifs.

C. Considérations légales

- **Public Records** : Les bar rolls sont des documents publics dans la plupart des états. Exception : l'ARDC (IL) est exempt de FOIA en tant qu'organe de la branche judiciaire.
- **Scraping** : Certains états interdisent explicitement l'accès automatisé (NJ : «automated program», FLSD : «commercial use prohibited»). Privilégier les demandes officielles.
- **Usage commercial** : La FL Bar interdit les «unauthorized uses». La GA Bar exige un «one-time use». Vérifier les conditions pour chaque source.
- **Règle d'or** : Mieux aucune information qu'une information fausse. Toute donnée d'avocat doit être traçable à sa source officielle.

D. Méthodologie

Cette analyse a été réalisée le 16 mars 2026 par 10 agents de recherche parallèles, couvrant :

- Les 5 state bars prioritaires (CA, FL, TX, IL, OH)

- 4 états supplémentaires (NJ, PA, MA, GA)
- Les sources fédérales/nationales (PACER, CourtListener, USPTO, EOIR)
- Les portails open data (data.gov, Kaggle, GitHub, Harvard Dataverse, Socrata)
- Les fournisseurs commerciaux (Martindale, Avvo, ZoomInfo, Data Axle, etc.)

Chaque source a été évaluée sur : complétude, coût, format, fraîcheur, présence de bar numbers, et conditions d'utilisation.